



流程圖一

1. 使用 Datasets 下載 Housing，並儲存成 housing.tab。(5%)

點擊兩下 Datasets widget 中 Housing dataset，會執行從 server 抓出 Housing dataset，並傳送到 output 的動作。但是由於題目要求執行儲存成 housing.tab，故我使用 Save Data widget 來幫助我儲存(見圖二、圖三)。



圖一、下載 Housing



圖二、使用 Save Data widget 儲存




圖三、確實儲存至 housing.tab


流程圖二

1. 開啟 housing.tab，分析 housing 中的資料筆數與屬性個數(feature)，並介紹每一屬性的意義。(15%)

使用 File widget 匯入 housing.tab(圖四)，並使用 Data Table widget 觀察 housing 中資料筆數與個數(圖五)。除此以外，從下載 housing dataset 的 Dataset widget 中我們可以連接到資料來源網站 <https://lib.stat.cmu.edu/datasets/boston>，從這裡我們可以看到關於資料內容的解釋(圖六)。由資料來源網站的解釋我也整理出每一屬性的意義，housing dataset 中總共 506 筆資料，1 個 numeric target，13 個 numeric feature(表一)。



圖四、匯入 housing.tab



圖五、從 Data Table widget 觀察 housing 資料

Variables in order:
 CRIM per capita crime rate by town
 ZN proportion of residential land zoned for lots over 25,000 sq.ft.
 INDUS proportion of non-retail business acres per town
 CHAS Charles River dummy variable (= 1 if tract bounds river; 0 otherwise)
 NOX nitric oxides concentration (parts per 10 million)
 RM average number of rooms per dwelling
 AGE proportion of owner-occupied units built prior to 1940
 DIS weighted distances to five Boston employment centres
 RAD index of accessibility to radial highways
 TAX full-value property-tax rate per \$10,000
 PTRATIO pupil-teacher ratio by town
 B $1000(B_k - 0.63)^2$ where B_k is the proportion of blacks by town
 LSTAT % lower status of the population
 MEDV Median value of owner-occupied homes in \$1000's

圖六、資料內容的解釋


表一、資料內容之解釋

Name	Type	Role	Explanation
MEDV	numeric	target	私有住宅的中位數價值(以千美元為單位)，亦即房價。
CRIM	numeric	feature	每個城鎮的人均犯罪率，用來衡量地區的治安狀況。
ZN	numeric	feature	住宅用地中，佔地超過 25,000 平方英尺的比例。用來衡量城市發住宅展狀況。
INDUS	numeric	feature	每個城鎮非零售業的營業面積比例。用來衡量城市商業發展狀況。
CHAS	numeric	feature	用於標示該地區是否靠近查爾斯河，1 代表靠近，0 代表不靠近。
NOX	numeric	feature	一氧化氮濃度（每千萬分之一單位），用來評估空氣指標。
RM	numeric	feature	每個住宅的平均房間數。
AGE	numeric	feature	1940 年前私有住宅的住房比率，可以得知該地區是否為新興城市或已發展很久。
DIS	numeric	feature	與五個波士頓就業中心的加權距離。
RAD	numeric	feature	放射狀高速公路可達性指數。
TAX	numeric	feature	每 1 萬美元的所需繳的財產稅，用來衡量房產稅的負擔。
PTRATIO	numeric	feature	每個城鎮的師生比例，用來衡量教育資源分配情況以及教育的品質。
B	numeric	feature	黑人比例。
LSTAT	numeric	feature	中下階級的人口比率。


流程圖二

2. 利用 Feature Statistics(10%)，Box Plot(10%)，Correlations(10%)分析屬性，並說明結果呈現的意義。

使用 Feature Statistics widget (圖七) 以及 Box Plot widget (圖八)分析屬性，整理內容如(表二)所示。






圖七、使用 Feature Statistics widget



圖八、使用 Box Plot widget





表二、Feature Statistics 與 Box Plot 的結果與意義

MEDV	 平均值：22.533、眾數：50.0、中位數：21.2、離散程度：0.408、最小值：5.0、最大值：50.0、缺失值：0、圖形呈常態分佈(normal distribution)。
CRIM	 平均值：3.6135236、眾數：0.01501、中位數：0.25651、離散程度：2.3780228、最小值：0.00632、最大值：88.97620、缺失值：0、圖形呈右偏態分佈(right-skewed)。資料集中在左側，可以推測大部分房子所在區域治安良好。
ZN	 平均值：11.364、眾數：0.0、中位數：0.0、離散程度：2.050、最小值：0.0、最大值：100.0、缺失值：0、圖形呈右偏態分佈(right-skewed)。資料集中左側，可推測資料中住宅所在位置較少大型住宅區，大於 50% 的住宅所在的城鎮沒有面積超過 25,000 平方英尺的住宅用地。


INDUS

<

	平均值：6.28463、眾數：5.713、中位數：6.20850、離散程度：0.1169、最小值：3.561、最大值：8.780、缺失值：0，資料中住宅房間數呈常態分配。																
AGE	^ Name Distribution Mean Mode Median Dispersion Min. Max. Missing  AGE <table border="1"> <thead> <tr> <th>Statistic</th> <th>Value</th> </tr> </thead> <tbody> <tr> <td>Mean</td> <td>68.575</td> </tr> <tr> <td>Mode</td> <td>100.0</td> </tr> <tr> <td>Median</td> <td>77.5</td> </tr> <tr> <td>Dispersion</td> <td>0.410</td> </tr> <tr> <td>Min.</td> <td>2.9</td> </tr> <tr> <td>Max.</td> <td>100.0</td> </tr> <tr> <td>Missing</td> <td>0 (0 %)</td> </tr> </tbody> </table>  68.575 ± 28.12 45.050 77.5 94.050 10.0 20.0 30.0 40.0 50.0 60.0 70.0 80.0 90.0 100.0 平均值：68.575、眾數：100.0、中位數：77.5、離散程度：0.410、最小值：2.9、最大值：100.0、缺失值：0，資料中住宅屋齡 left-skewed，資料集中後半部，代表屋齡普遍較高。	Statistic	Value	Mean	68.575	Mode	100.0	Median	77.5	Dispersion	0.410	Min.	2.9	Max.	100.0	Missing	0 (0 %)
Statistic	Value																
Mean	68.575																
Mode	100.0																
Median	77.5																
Dispersion	0.410																
Min.	2.9																
Max.	100.0																
Missing	0 (0 %)																
DIS	^ Name Distribution Mean Mode Median Dispersion Min. Max. Missing  DIS <table border="1"> <thead> <tr> <th>Statistic</th> <th>Value</th> </tr> </thead> <tbody> <tr> <td>Mean</td> <td>3.795043</td> </tr> <tr> <td>Mode</td> <td>3.4952</td> </tr> <tr> <td>Median</td> <td>3.207450</td> </tr> <tr> <td>Dispersion</td> <td>0.554310</td> </tr> <tr> <td>Min.</td> <td>1.1296</td> </tr> <tr> <td>Max.</td> <td>12.1265</td> </tr> <tr> <td>Missing</td> <td>0 (0 %)</td> </tr> </tbody> </table>  3.795043 ± 2.10363 2.100350 3.207450 5.164950 2.0000 4.0000 6.0000 8.0000 10.0000 12.0000 14.0000 平均值：3.795043、眾數：3.4952、中位數：3.207450、離散程度：0.554310、最小值：1.1296、最大值：12.1265、缺失值：0，資料呈右偏態分佈(right-skewed)。	Statistic	Value	Mean	3.795043	Mode	3.4952	Median	3.207450	Dispersion	0.554310	Min.	1.1296	Max.	12.1265	Missing	0 (0 %)
Statistic	Value																
Mean	3.795043																
Mode	3.4952																
Median	3.207450																
Dispersion	0.554310																
Min.	1.1296																
Max.	12.1265																
Missing	0 (0 %)																
RAD	^ Name Distribution Mean Mode Median Dispersion Min. Max. Missing  RAD <table border="1"> <thead> <tr> <th>Statistic</th> <th>Value</th> </tr> </thead> <tbody> <tr> <td>Mean</td> <td>9.55</td> </tr> <tr> <td>Mode</td> <td>24</td> </tr> <tr> <td>Median</td> <td>5</td> </tr> <tr> <td>Dispersion</td> <td>0.91</td> </tr> <tr> <td>Min.</td> <td>1</td> </tr> <tr> <td>Max.</td> <td>24</td> </tr> <tr> <td>Missing</td> <td>0 (0 %)</td> </tr> </tbody> </table>  9.55 ± 8.7 4 5 24 5 10 15 20 25 平均值：9.55、眾數：24、中位數：5、離散程度：0.91、最小值：1、最大值：24、缺失值：0，資料分散。	Statistic	Value	Mean	9.55	Mode	24	Median	5	Dispersion	0.91	Min.	1	Max.	24	Missing	0 (0 %)
Statistic	Value																
Mean	9.55																
Mode	24																
Median	5																
Dispersion	0.91																
Min.	1																
Max.	24																
Missing	0 (0 %)																
TAX	^ Name Distribution Mean Mode Median Dispersion Min. Max. Missing  TAX <table border="1"> <thead> <tr> <th>Statistic</th> <th>Value</th> </tr> </thead> <tbody> <tr> <td>Mean</td> <td>408.24</td> </tr> <tr> <td>Mode</td> <td>666</td> </tr> <tr> <td>Median</td> <td>330</td> </tr> <tr> <td>Dispersion</td> <td>0.41</td> </tr> <tr> <td>Min.</td> <td>187</td> </tr> <tr> <td>Max.</td> <td>711</td> </tr> <tr> <td>Missing</td> <td>0 (0 %)</td> </tr> </tbody> </table>	Statistic	Value	Mean	408.24	Mode	666	Median	330	Dispersion	0.41	Min.	187	Max.	711	Missing	0 (0 %)
Statistic	Value																
Mean	408.24																
Mode	666																
Median	330																
Dispersion	0.41																
Min.	187																
Max.	711																
Missing	0 (0 %)																

	 平均值：408.24、眾數：666、中位數：330、離散程度：0.41、最小值：187、最大值：711、缺失值：0，有一部分資料住宅的房屋稅特別高，但大部分都集中在中位數附近。
PTRATIO	 平均值：18.456、眾數：20.2、中位數：19.050、離散程度：0.117、最小值：12.6、最大值：22.0、缺失值：0，資料中住宅的師生比例有些許差異。
B	 平均值：356.6740、眾數：396.90、中位數：391.44、離散程度：0.2557、最小值：0.32、最大值：396.90、缺失值：0，資料中住宅的黑人數集中在中位數附近，但有少部分住宅幾乎沒有黑人。
LSTAT	 平均值：12.6531、眾數：6.36、中位數：11.36、離散程度：0.5638、最小值：1.73、最大值：37.97、缺失值：0，資料中中下階層比例呈右偏態分佈(right-skewed)，分佈有些差異。

使用 Correlation widget 設定 target 是 MEDV。我們可以發現與 MEDV 正相關的 feature 有 RM、ZN、B、DIS、CHAS，與 MEDV 負相關的有 LSTAT、PTRATIO、INDUS、TAX、NOX、CRIM、RAD、AGE。一般來說， $|r| < 0.3$ 為低度線性相關； $0.3 \leq |r| < 0.7$ 為顯著性相關； $0.7 \leq |r| < 1$ 為高度線性相關。根據此一規則可以得出 LSTAT、RM 屬於高度線性相關。(圖九)




圖九、使用 Correlation widget


流程圖三

1. 將資料分為 80% 訓練 20% 測試，利用 Predictions 的 MAPE 效能指標，找出 Linear Regression 的較佳正規化參數。必須列出所有嘗試過的結果，並從中挑出最佳的參數值。

以下(圖十)、(圖十一)是我將資料利用 Data Sampler widget 分為 80% 訓練 20% 測試，(圖十二)是從 Prediction widget 看嘗試過的所有結果，以 MAPE 的結果來觀察可以得知，Alpha 值越大，MAPE 也越大，其中又以 Lasso0.01、Ridge0.1、Ridge0.01 表現較好皆為 0.168。



圖十、流程圖三



圖十一、Data Sampler


Model	MSE	RMSE	MAE	MAPE	R2
Lasso 100	65.991	8.123	5.886	0.292	0.246
Lasso 10	40.297	6.348	4.441	0.203	0.540
Lasso 1	26.501	5.148	3.663	0.177	0.697
Lasso 0.1	23.002	4.796	3.400	0.173	0.737
Lasso 0.01	21.921	4.682	3.331	0.168	0.750
Linear Regression	21.886	4.678	3.335	0.168	0.750
Ridge 100	23.854	4.884	3.501	0.174	0.727
Ridge 10	22.668	4.761	3.387	0.172	0.741
Ridge 1	22.068	4.698	3.339	0.169	0.748
Ridge 0.1	21.891	4.679	3.333	0.168	0.750
Ridge 0.01	21.886	4.678	3.335	0.168	0.750

圖十二、Prediction 測試結果


流程圖四

1. 刪除較為不重要特徵，並說明刪除的理由。

由 correlation 比較與 MEDV 的相關性可以發現 CHAS 的相關性只有+0.175，因此我利用 Select Column widget 篩選掉 CHAS(圖十四)再重新得到一個 prediction(圖十五)。刪除後可以發現和刪除前(圖十二)沒有明顯差異。



圖十三、流程圖四



圖十四、移除 CHAS

Shown regression error: Difference									
	Lasso 100	error	Lasso 10	error	Lasso 1	error	Lasso 0.1	error	ME
1	25.2	1.6	25.8	2.2	28.7	5.1	29.1	5.5	23.6
2	26.2	-6.2	30.4	-2.0	32.7	0.3	33.5	1.1	32.4
3	15.8	2.2	16.4	2.8	11.9	-1.7	11.5	-2.1	13.6

Show performance scores					
Model	MSE	RMSE	MAE	MAPE	R2
Lasso 100	65.991	8.123	5.886	0.292	0.246
Lasso 10	40.297	6.348	4.441	0.203	0.540
Lasso 1	26.501	5.148	3.663	0.177	0.697
Lasso 0.1	23.124	4.809	3.408	0.173	0.736
Lasso 0.01	22.247	4.717	3.355	0.170	0.746
Linear Regression	22.214	4.713	3.363	0.170	0.746
Ridge 100	23.966	4.895	3.508	0.174	0.726
Ridge 10	22.928	4.788	3.400	0.173	0.738
Ridge 1	22.383	4.731	3.357	0.170	0.744
Ridge 0.1	22.219	4.714	3.359	0.170	0.746
Ridge 0.01	22.214	4.713	3.362	0.170	0.746

圖十五、重新得到 prediction