



事前準備：

首先先到 Kaggle 中下載 Economic Freedom of the World 資料集，在這裡會下載一個 efw_cc.csv 的檔案。接著我們會利用 File Widget 去讀取這個檔案。



圖一、Kaggle 資料集



圖二、匯入下載好的資料集(cfw_cc.csv)

1. 簡單說明資料集與其中所有屬性的意義。


表一、資料集與其中屬性的意義

Name	Type	Explanation
ISO_Code	text	國際標準化組織 (ISO) 的三字母國家代碼，用於明確識別國家。
Countries	text	國家名稱，用以描述每筆資料所屬國家。
Year	numeric	資料觀察的年份，用於描述經濟自由度在特定年份

		的情況。
Economic freedom	numeric	經濟自由的總分，範圍從 0 至 10，分數越高表示該國經濟自由程度越高。
Rank	numeric	經濟自由度的全球排名（1 代表最自由），排名越小代表經濟自由度越高。
Quartile	numeric	經濟自由度四分位組別，範圍為 1-4，其中 1 表示排名前 25% 的國家。
1a_government_consumption	numeric	政府消費支出占總消費支出比例的評估（越低越好）。
1b_transfers	numeric	政府轉移支付與補貼的規模，規模越小自由度越高。
1c_gov_enterprises	numeric	政府經營企業的數量及經濟規模占比，越少表示政府干預越少。
1d_top_marg_tax_rate	numeric	最高邊際稅率（包含個人所得稅與公司稅），稅率越低自由度越高。
1_size_government	numeric	上述 4 項指標的綜合分數，表示整體政府規模，越高越自由。
2a_judicial_independence	numeric	司法獨立程度的評估。
2b_impartial_courts	numeric	法院判決是否公正無偏頗。
2c_protection_property_rights	numeric	財產權保障程度，越高表示財產權越有保障。
2d_military_interference	numeric	軍方干涉法律與政治的程度，越低越自由。
2e_integrity_legal_system	numeric	法律系統的清廉程度（無腐敗），越高越好。
2f_legal_enforcement_contracts	numeric	約執行效率與可信度。
2g_restrictions_sale_real_property	numeric	房地產交易的限制程度，越低自由度越高。
2h_reliability_police	numeric	警察系統的可靠度與可信度。
2i_business_	numeric	犯罪對企業的經營成本影響程度（越低越好）。

costs_crime		
2j_gender_adj justment	numeric	性別平等指標（男女享有財產權的平等程度）。
2_property_r ights	numeric	上述 10 項指標的整體綜合分數，表示財產權保護程度。
3a_money_gr owth	numeric	貨幣供應量增長速度，穩定的貨幣供給增長更佳。
3b_std_inflati on	numeric	通貨膨脹的標準差，數值越低表示貨幣穩定性越高。
3c_inflation	numeric	通貨膨脹率，越低越好。
3d_freedom_ own_foreign_ _currency	numeric	個人擁有外幣的自由度，越高表示貨幣自由度越高。
3_sound_mo ney	numeric	貨幣健全程度的綜合分數。
4a_tariffs	numeric	關稅水準（越低越好）。
4b_regulator y_trade_barri ers	numeric	貿易法規上的限制程度（越低越好）。
4c_black_ma rket	numeric	黑市交易的規模，反映合法市場的開放度（越小越好）。
4d_control_ movement_c apital_ppl	numeric	對資金及人員跨國移動的管制程度（越低越好）。
4_trade	numeric	國際貿易自由度的綜合評估分數。
5a_credit_ma rket_reg	numeric	信貸市場的自由度，信貸取得容易性越高分數越高。
5b_labor_ma rket_reg	numeric	勞動市場的自由程度，勞動法規越少管制越自由。
5c_business_ reg	numeric	商業經營的自由程度（創業與公司經營的容易性與限制少）。
5_regulation	numeric	政府管制自由度的綜合指標。

- 將 ISO_code 與 countries 維持/設定為 meta attribute，接著使用 Feature Statistic 分析並說明其他欄位的值區間與空值比例。



圖三、維持 Meta attribute



圖四、使用 feature statistics 查看值區間、空值比例

表二、其他欄位值區間與空值比例


Year	值區間：1970-2016、空值比例：0%
Economic freedom	值區間：1.97-9.19、空值比例：19%
Rank	值區間：1-162、空值比例：19%
Quartile	值區間：1-4、空值比例：19%
1a_government consu mption	值區間：0.00-10、空值比例：19%

1b_tranfers	值區間：0.00-10、空值比例：26%
1c_gov_enterprises	值區間：0-10、空值比例：17%
1d_top_marg_tax_rate	值區間：0.0-10.0、空值比例：28%
1_size_government	值區間：0.653797-9.90465、空值比例：17%
2a_judicial_independence	值區間：0.00-9.81667、空值比例：42%
2b_impartial_courts	值區間：0.00-9.686、空值比例：32%
2c_protection_property_rights	值區間：0.00-10、空值比例：30%
2d_military_interference	值區間：0.00-10、空值比例：32%
2e_integrity_legal_system	值區間：0.00-10、空值比例：31%
2f_legal_enforcement_contracts	值區間：0.00-8.47871、空值比例：37%
2g_restrictions_sale_real_property	值區間：0.00-9.9811、空值比例：37%
2h_reliability_police	值區間：0.00-9.68824、空值比例：56%
2i_business_costs_crime	值區間：0.00-9.67261、空值比例：56%
2j_gender_adjustment	值區間：0.00-1、空值比例：2%
2_property_rights	值區間：0.955583-9.27833、空值比例：20%
3a_money_growth	值區間：0.00-9.99903、空值比例：17%
3b_std_inflation	值區間：0.00-9.95231、空值比例：16%
3c_inflation	值區間：0.00-10、空值比例：16%
3d_freedom_own_foreign_currency	值區間：0.00-10、空值比例：17%
3_sound_money	值區間：0.00-9.92219、空值比例：16%
4a_tariffs	值區間：0.00-10、空值比例：18%
4b_regulatory_trade_barriers	值區間：0.00-9.83333、空值比例：36%
4c_black_market	值區間：0.00-10、空值比例：17%
4d_control_movement_capital_ppl	值區間：0.00-10、空值比例：16%
4_trade	值區間：0.00-10、空值比例：19%
5a_credit_market_reg	值區間：0.00-10、空值比例：17%


5b_labor_market_reg	值區間：1.83717-9.725、空值比例：31%
5c_business_reg	值區間：2.00984-9.50374、空值比例：38%
5_regulation	值區間：1.002-9.43983、空值比例：20%

3. 刪除 2005 年（含）以前的資料，並比較刪除 2005 年的資料前後，資料的空值數量差異。

利用 Select Rows 選擇 is greater than 來比較原先完整資料與刪除 2005 年(含)以前的資料的結果，並比較前後數量差異。



圖五、刪除 2005 年(含)的方法




圖六、查看 feature statistics 觀察空值

表三、空值數量的前後差異


Year	空值數量：刪除前 0，刪除後 0
Economic freedom	空值數量：刪除前 723，刪除後 122
Rank	空值數量：刪除前 723，刪除後 122
Quartile	空值數量：刪除前 723，刪除後 122
1a_government_consumption	空值數量：刪除前 589，刪除後 98
1b_transfers	空值數量：刪除前 960，刪除後 223
1c_gov_enterprises	空值數量：刪除前 646，刪除後 134
1d_top_marg_tax_rate	空值數量：刪除前 1047，刪除後 200
1_size_government	空值數量：刪除前 647，刪除後 122
2a_judicial_independence	空值數量：刪除前 1553，刪除後 243
2b_impartial_courts	空值數量：刪除前 1179，刪除後 122
2c_protection_property_rights	空值數量：刪除前 1129，刪除後 245
2d_military_interference	空值數量：刪除前 1186，刪除後 122
2e_integrity_legal_system	空值數量：刪除前 1153，刪除後 349
2f_legal_enforcement_contracts	空值數量：刪除前 1361，刪除後 139
2g_restrictions_sale_real_property	空值數量：刪除前 1384，刪除後 149
2h_reliability_police	空值數量：刪除前 2071，刪除後 247
2i_business_costs_crime	空值數量：刪除前 2071，刪除後 247
2j_gender_adjustment	空值數量：刪除前 66，刪除後 30
2_property_rights	空值數量：刪除前 755，刪除後 121
3a_money_growth	空值數量：刪除前 644，刪除後 112
3b_std_inflation	空值數量：刪除前 607，刪除後 114
3c_inflation	空值數量：刪除前 607，刪除後 114
3d_freedom_own_foreign_currency	空值數量：刪除前 621，刪除後 122
3_sound_money	空值數量：刪除前 611，刪除後 124
4a_tariffs	空值數量：刪除前 681，刪除後 127

4b_regulatory_trade_barriers	空值數量：刪除前 1348，刪除後 128
4c_black_market	空值數量：刪除前 617，刪除後 129
4d_control_movement_capital_ppl	空值數量：刪除前 592，刪除後 121
4_trade	空值數量：刪除前 691，刪除後 123
5a_credit_market_reg	空值數量：刪除前 619，刪除後 122
5b_labor_market_reg	空值數量：刪除前 1158，刪除後 128
5c_business_reg	空值數量：刪除前 1402，刪除後 128
5_regulation	空值數量：刪除前 728，刪除後 122


4. 刪除 Economic Freedom 為空值的所有 instances，接著請用欄位平均值填補每一欄的空值。



圖七、刪除 Economic Freedom 為空值的所有 instances




圖八、利用 impute widget 將欄位平均值填補每一欄的空值




圖九、第四題流程

5. 將 year, rank 設為 meta attribute；3d_freedom_own_foreign_currency 設為 target。




圖十、設定 meta attribute 以及 target




圖十一、第五題流程

6. 將資料分為 80%訓練、20%測試，建立 Decision tree 模型。接著就「Min number of instances in leaves」與「Do not split subsets smaller than」兩個參數的不同組合，分別探討是否出現 overfitting。


利用 data sampler widget 將資料分為 80%訓練、20%測試(圖十二)。接著建立 decision tree，建立方式為使用 Tree widget，同時針對「Min number of instances in leaves」(圖十三)與「Do not split subsets smaller than」(圖十四)兩個參數的不同組合進行參數設置。在我的流程圖中可以看到我是由上到下分別設置參數為 1,2,3,4(圖十六)。最後我利用 test & score widget 評估模型效能，我發現 Min number of instances in leaves 有出現 overfitting，因為訓練集上的表現均比測試集上好很多。而 Do not split subsets smaller than 也有出現 overfitting，因為訓練集上的表現同樣比測試集上好很多。




圖十三、Data sampler



圖十四、設置 Min number of instances in leaves



圖十五、設置 Do not split subsets smaller than



圖十六、第六題流程圖

Test and Score - Orange

Cross validation
 Number of folds: 5
 Stratified
 Cross validation by feature
 Random sampling
 Repeat train/test: 10
 Training set size: 66 %
 Stratified
 Leave one out
 Test on train data
 Test on test data


Model	MSE	RMSE	MAE	MAPE	R2
tree_leaves_01	0.000	0.000	0.000	0.000	1.000
tree_leaves_02	0.135	0.367	0.054	59347133643813.016	0.992
tree_leaves_03	0.195	0.441	0.078	67825295592929.156	0.989
tree_leaves_04	0.286	0.535	0.115	97498862414835.656	0.983
tree_split_01	0.000	0.000	0.000	0.000	1.000
tree_split_02	0.000	0.000	0.000	0.000	1.000
tree_split_03	0.028	0.168	0.011	8478161949116.145	0.998
tree_split_04	0.078	0.280	0.031	42390809745580.727	0.995

Compare models by: Mean square error
 Negligible diff.: 0.1

	tree_le...	tree_le...	tree_le...	tree_le...	tree_s...	tree_s...	tree_s...
tree_leaves_01							
tree_leaves_02							
tree_leaves_03							
tree_leaves_04							
tree_split_01							
tree_split_02							
tree_split_03							
tree_split_04							

Table shows probabilities that the score for the model in the row is higher than that of the model in the column. Small numbers show the probability that the difference is negligible.


圖十七、Test on train data(用 80% 資料來測試)




圖十八、Test on test data(用 20%剩餘的資料來測試)

- 分別以訓練資料比例 50%、60%、70%、75%、80%、85%、90% 建立 Decision tree，並將資料分割比例與 CA 值存入 data table，再繪出散點圖。(訓練資料比例為 x 軸、CA 值為 y 軸的散點)

首先，為了得到 CA 值，我將非 categorical 的 target 轉成 categorical，分類方式為 <5, 5-10(不含 10), >=10 (圖十九)。接著以訓練資料比例 50%、60%、70%、75%、80%、85%、90% 建立 Decision tree，利用 Test & score widget、Confusion Matrix 產出 CA 值(圖二十)。再來，為了畫成 scatter plot，我將 CA 值另外用 EXCEL 記錄下來並利用 file widget 匯入(圖二十一、圖二十二)。最後，利用 data table 儲存，並畫出 scatter plot。




圖十九、利用 discretize 將 target 轉成 categorical




圖二十、第七題流程圖

	A	B
1	train	CA
2	50%	0.98
3	60%	0.991
4	70%	0.995
5	75%	0.99
6	80%	0.992
7	85%	0.982
8	90%	0.982



圖二十一、紀錄於 excel 中 圖二十二、利用 file widget 匯入



圖二十三、scatter plot