



流程圖一

1. 打開 Churn_Modelling.csv，查看資料的詳細屬性，找出有空值的屬性，並以 box plot 說明它們的特性。


首先，下載 Churn_Modeling.csv，並用 File widget 打開(圖一)。利用 feature statistics widget 觀察有空值的屬性，這裡可以發現有 14 個空值(圖三)。接著用 box plot widget 觀察有空值的屬性的特性(表一)。



圖一、打開 Churn_Modeling



圖二、流程圖一




圖三、觀察 Missing Value(6+4+4=14)

表一、觀察有空值的屬性，並以 box plot 說明特性


Age	平均值為 38.93，資料集中在 32 到 44 之間。區間很大，最小值 18，最大值 92。
Gender	男生人數 5453 人，女生人數 4543 人，男女比為 55:45
EstimatedSalary	平均100074.7411，資料較為分散，薪資區間很大，最小值11.58，最大值199992.48。

前處理




圖四、前處理完整流程圖

1. 接下來資料都將修改以下屬性：{'CredRate' = 'CreditScore'; 'ActMem' = 'IsActiveMember'; 'Prod Number' = 'NumOfProducts'; 'Exited' = 'Churn'; 本題我利用 editdomain 進行改名。



圖五、利用 edit domain widget 進行改名


2. 將 CustomerId 的 Role 設為 meta, Churn 的 Role 改為 target 利用 select columns widget 對 CustomerId、Churn 進行修改



圖六、利用 select column widget 進行修改

3. 將 HasCrCard 與 IsActiveMember 改為 numeric


利用 editdomain 對 HasCrCard 與 IsActiveMember 進行修改。



圖七、利用 edit domain widget 進行修改

4. 將所有空值用 average/most frequent 補值


利用 impute widget 進行補值。



圖八、利用 impute widget 進行補值

5. 利用 Continuize 的 one-hot encoding 的方式轉變 Geography 與 Gender。


本題我利用 Continuize 的 one-hot encoding 轉變 Geography 與 Gender，可以看到圖中為 one-hot。



圖九、利用 Continuize 的 one-hot encoding 轉變 Geography 與 Gender

流程圖二

以所有資料建立 Logistic Regression 模型，並利用模型的 coefficients 檢驗頭 50 筆資料的預測值是否正確。



圖十、流程圖二

我將模型的係數輸出並紀錄於名為 coefficient 的 data table 中(圖十一)。由於 logistic regression 就是利用 sigmoid function 將值轉換成機率，因此要檢測頭 50 筆資料的預測值是否正確，我先建立一個名為 sigmoid 的 formula widget，在裡面建立一個名為 Logistic_Regression_new 的屬性，此屬性利用 coefficient 計算我的 sigmoid function(圖十二)。我的 sigmoid function 如下：

$$\frac{1}{1+\exp(-(\text{CreditScore}*(-0.000735208)+\text{Geography_France}*(-0.865429)+\text{Geography_Germany}*(-0.0867605)+\text{Geography_Spain}*(-0.82469)+\text{Gender_Female}*(-0.626623)+\text{Gender_Male}*(-1.15026)+\text{Age}*0.0721369+\text{Tenure}*(-0.0168501)+\text{Balance}*0.00000257329+\text{NumOfProducts}*(-0.112878)+\text{HasCrCard}*(-0.0671489)+\text{IsActiveMember}*(-1.06732)+\text{EstimatedSalary}*0.0000004563-1.79506)))}$$

建立完畢後會進行預測並將資料存入 Logistic_Regression_new 的欄位中。為了方便比較，我使用 merge data 將資料 merge 再進行後續比較。(圖十三、圖十四)

	name	1
1	intercept	-1.79506
2	CreditScore	-0.000735208
3	Geography=Fr...	-0.865429
4	Geography=G...	-0.0867605
5	Geography=S...	-0.82469
6	Gender=Female	-0.626623
7	Gender=Male	-1.15026
8	Age	0.0721369
9	Tenure	-0.0168501
10	Balance	2.57329e-06
11	NumOfProducts	-0.112878
12	HasCrCard	-0.0671489
13	IsActiveMember	-1.06732
14	EstimatedSalary	4.563e-07

圖十一、coefficient data table

Variable Definitions

New gistic_Regression_new 1ember*(-1.06732)+EstimatedSalary*0.000004563-1.79506))

Remove Meta attribute Select Feature Select Function

N Logistic_Regression_new:= 1/(1+exp(-(CreditScore*(-0.000735208)+Geography_France*(-0.865429)+Ge...

Send

圖十二、formula widget 中內容

比較 Logistic_Regression_new 和 Logistic_Regression(1)的前 50 筆資料，發現兩者所得到之資料相同並無差異。

	Churn	CustomerId	Logistic Regression	Logistic Regression (0)	Logistic Regression (1)	Logistic_Regression_new	Logistic Regression (error)	Selected
1	1	15634602	0	0.875147	0.124853	0.124853	0.875147	No
2	0	15647311	0	0.841014	0.158986	0.158986	0.158986	No
3	1	15619304	0	0.669113	0.330887	0.330886	0.669113	No
4	0	15701354	0	0.766289	0.233711	0.233711	0.233711	No
5	0	15737888	0	0.844407	0.155593	0.155592	0.155593	No
6	1	15574012	0	0.757098	0.242902	0.242901	0.757098	No
7	0	15592531	0	0.90736	0.0926398	0.0926391	0.0926398	No
8	1	15656148	0	0.716763	0.283237	0.283236	0.716763	No
9	0	15792365	0	0.877159	0.122841	0.122841	0.122841	No
10	0	15592389	0	0.96331	0.03669	0.0366897	0.03669	No
11	0	15767821	0	0.80514	0.19486	0.194859	0.19486	No
12	0	15737173	0	0.836997	0.163003	0.163002	0.163003	No
13	0	15632264	0	0.782202	0.217798	0.217798	0.217798	No
14	0	15691483	0	0.891894	0.108106	0.108106	0.108106	No
15	0	15600882	0	0.933175	0.066825	0.0668247	0.066825	No
16	0	15643966	0	0.765802	0.234198	0.234196	0.234198	No
17	1	15737452	1	0.306093	0.693907	0.693906	0.306093	No
18	0	15788218	0	0.968447	0.0315533	0.0315532	0.0315533	No
19	0	15661507	0	0.749694	0.250306	0.250305	0.250306	No
20	0	15568982	0	0.971417	0.0285832	0.028583	0.0285832	No
21	0	15577657	0	0.943125	0.0568746	0.0568746	0.0568746	No
22	0	15597945	0	0.854466	0.145534	0.145534	0.145534	No
23	1	15699309	0	0.745222	0.254778	0.254777	0.745222	No
24	0	15725737	0	0.910849	0.0891506	0.0891499	0.0891506	No
25	0	15625047	0	0.91788	0.0821204	0.0821201	0.0821204	No
26	0	15738191	0	0.976301	0.0236988	0.0236986	0.0236988	No
27	0	15736816	0	0.863227	0.136773	0.136772	0.136773	No
28	0	15700772	0	0.804772	0.195228	0.195227	0.195228	No
29	0	15728693	0	0.671948	0.328052	0.328051	0.328052	No
30	1	15656300	0	0.969952	0.0390476	0.0390473	0.0390476	No
31	1	15599475	0	0.778988	0.221012	0.221012	0.778988	No
32	0	15706552	0	0.931679	0.0683206	0.06832	0.0683206	No
33	0	15750181	0	0.631281	0.368719	0.368718	0.368719	No
34	0	15659428	0	0.885396	0.114604	0.114604	0.114604	No
35	0	15732963	0	0.958205	0.041795	0.0417948	0.041795	No

圖十三、前 35 筆資料比較

	Churn	CustomerId	Logistic Regression	Logistic Regression (0)	Logistic Regression (1)	Logistic Regression new	Logistic Regression (error)	Selected
36	1	15794171	0	0.552803	0.447197	0.447196	0.552803	No
37	0	15788448	0	0.936962	0.0630376	0.0630371	0.0630376	No
38	0	15729599	0	0.931464	0.0685357	0.0685351	0.0685357	No
39	0	15717426	0	0.951404	0.0485961	0.0485957	0.0485961	No
40	0	15585768	0	0.856179	0.143821	0.14382	0.143821	No
41	0	15619360	0	0.80953	0.19047	0.190469	0.19047	No
42	1	15738148	1	0.450083	0.549917	0.549916	0.450083	No
43	0	15687946	0	0.557609	0.442391	0.44239	0.442391	No
44	1	15755196	0	0.521321	0.478679	0.478678	0.521321	No
45	0	15684171	0	0.547195	0.452805	0.452803	0.452805	No
46	0	15754849	0	0.865169	0.134831	0.13483	0.134831	No
47	1	15602280	0	0.902585	0.0974153	0.0974149	0.902585	No
48	1	15771573	0	0.760248	0.239752	0.239751	0.760248	No
49	0	15766205	0	0.832243	0.167757	0.167756	0.167757	No
50	0	15771873	0	0.594092	0.405908	0.405908	0.405908	No
51	0	15616550	0	0.608931	0.391069	0.391068	0.391069	No
52	0	15768193	0	0.68135	0.31865	0.318649	0.31865	No
53	0	15683553	0	0.851013	0.148987	0.148987	0.148987	No
54	1	15702298	0	0.620066	0.399934	0.399932	0.620066	No
55	1	15569590	0	0.591301	0.408699	0.408698	0.591301	No
56	0	15760861	0	0.88637	0.113629	0.113629	0.11363	No
57	0	15630053	0	0.719579	0.280421	0.280419	0.280421	No
58	0	15647091	0	0.890053	0.109947	0.109947	0.109947	No
59	1	15623944	1	0.290636	0.709364	0.709363	0.290636	No
60	0	15804771	0	0.854692	0.145308	0.145307	0.145308	No
61	0	15651280	0	0.702494	0.297506	0.297505	0.297506	No
62	0	15773469	0	0.729785	0.270215	0.270214	0.270215	No
63	0	15702014	0	0.859872	0.140128	0.140128	0.140128	No
64	0	15751208	0	0.796972	0.203028	0.203027	0.203028	No
65	0	15592461	0	0.9303	0.0696998	0.0696992	0.0696998	No
66	0	15789484	0	0.813859	0.186141	0.18614	0.186141	No
67	0	15696061	0	0.590951	0.409049	0.409048	0.409049	No
68	0	15641582	0	0.839977	0.169623	0.169622	0.169623	No
69	0	15638424	0	0.803328	0.196672	0.196672	0.196672	No
70	0	15755648	0	0.910673	0.0893271	0.0893269	0.0893271	No
71	1	15703793	1	0.397945	0.602055	0.602053	0.397945	No
72	0	15620344	0	0.929703	0.0702973	0.0702969	0.0702973	No
73	0	15812518	0	0.85807	0.14193	0.141929	0.14193	No
74	0	15779052	0	0.896681	0.103319	0.103318	0.103319	No
75	0	15770811	0	0.952323	0.0476773	0.0476769	0.0476773	No

圖十四、第 35~50 筆資料的比較


流程圖三

1. 以 10-fold 交叉驗證方式，找出 CA 值最高的 SVM 參數組合。


本題要找出 CA 值最高的參數組合，在經過一個晚上數百次的調參數測試後，我得到的最佳值是 0.853，以 SVM_best 表示(圖十六)，採用的參數見圖十七。此數值有高於採用預設 Logistic Regression 的 0.810。

在設計參數時我會固定變量進行設計。例如，在圖十五中，我固定 $C=0.5$ 並測試 g 在多少時會是最好。我也有嘗試固定 $g=0.5$ ， C 調整為多少時會是最好。至於為何是選 0.5? 原因是我測試了一個晚上得出來的經驗，大約在 0.5 會有較優秀的結果。


心得：一開始在調整參數時我非常挫折，我的 CA 值一度在 0.78 左右無法上升，但最後我利用提高 Iteration limit 的方式幫助我將 CA 值得到最好的值 0.853。



圖十五、流程圖三



圖十六、觀察 SVM 結果




圖十七、SVM 最佳值所使用的參數


2. 固定 kernel function，改變不同 C 值，繪出 C 值與 support vectors 個數的散點關係圖。

本題我利用前一題的參數，並改變 C 值，描繪出 C 值與 support vectors 個數的 scatter plot。(圖十八)

為了得到 support vectors 個數，我在模型跑完後輸出 support vector 到 data table 用於觀察每種不同 C 值的數量 support vector 的數量(如圖十九)。接著，我使用 excel 記錄我的 C 值與對應的 support vectors 數量，並存成 support_vector.csv(圖二十)，再利用 file widget 匯入 support_vector.csv。最後再連接 scatter plot widget 畫出散點關係圖(圖二一)。




圖十八、流程圖三



圖十九、C=500 時 support vector 數為 944

	A	B	C
C值	support vector個數		
0.1	2000		
0.5	2000		
1	2000		
5	1594		
10	1402		
50	944		
100	966		
500	628		

圖二十、support vector.csv



圖二一、C 值與 support vector 數散點圖(C=0.1,0.5,1.0 support vector 均為 2000)