


流程圖一




1. 打開 four_cols.csv，並以 Data Table 說明資料集內容。(5%)



在 File 中打開 four_cols.csv，並將 File 連至 Data Table，了解此資料集的內容。資料 four_cols 資料集有 1000 筆資料，有 4 個屬性，沒有 target 變數，資料集記錄著 income(收入)、age(年齡)、days_since_purchase(最近一次購買的天數)與 annual_spend(年度支出)。我認為這個資料集是用於分析消費者購物行為的資料，能夠協助企業了解如何拉攏客戶。


2. 使用 PCA 將資料降為 2 維，接著用新的緯度空間在 Scatter Plot 當中繪圖。請說明繪圖結果是否可以清楚看到 3 個群集。(10%)

流程圖一




將 File 連至 PCA Widget，在 PCAWidget 中將 components 設定為 2，把資料降成 2 維，接著再將 PCA 連至 Scatter Plot 觀察群集分布。在 Scatter Plot 中將 x 軸設為降維後的第一維(PC1)，將 y 軸降維後的第二維(PC2)，呈現的結果如上圖，可以清楚看到會分成 3 個群集。

流程圖二




1. 使用 k-Means 設定 k=3, initialize with KMeans++分群 four_cols.csv，再透過 PCA 降資料為 2 維，最後利用 Scatter Plot 繪出分群後的散點圖（不同群集的資料要用的不同顏色與不同的形狀代表）。(5%)



將 File 匯入 four_col 檔案並連至 k-Means widget，其中把 Fixed 的值設為 3，並且將 Initialization 設為 Initialize with KMeans++，再將 k-Means 連至 PCA 降維成 2 維，最後再將 PCA 連至 Scatter Plot 繪出散點圖。在 Scatter Plot 中，x 軸是 PC1，y 軸是 PC2，另外要將 Color 和 Shape 選取為 Cluster，讓不同群集的資料用不同顏色、不同形狀來呈現。


2. 同上，分別改變 k=4, k=5，繪出分群後的散點圖。(10%)

設定 k=4：




跟上一小題進行一樣的連接方式，但將 Fixed 中的值設為 4，代表分成 4 群，散點圖的結果如上圖。(PCA 操作完全一樣，故不再附上截圖)

設定 k=5：




跟上一小題進行一樣的連接方式，但將 Fixed 中的值設為 5，代表分成 5 群，散點圖的結果如上圖。(PCA 操作完全一樣，故不再附上截圖)


流程圖三



1. 使用 silhouette score 的評估方式為 k-Means 選定最佳 k 值，並說明最佳 k 值是否異於流程圖一視覺化看到的群集數。(10%)




將File連至k-Means，並將分群數設為From，再將Initialization設為Initialize with KMeans++。這樣的設定能夠得到不同k值的silhouette score，而我們觀察後會發現當k=5時，具有最高的silhouette score值。因此最佳k值是5，此時silhouette score為0.473，和流程圖一的群集數不同，流程圖一的群集數為3。




當將不同群集的資料用的不同顏色與不同的形狀來呈現時(如上方右圖)，會發現最佳 k 值下所呈現的散點圖中的群集數是異於流程圖一視覺化所看到的群集數，在流程圖一能看出資料分成 3 群，然而在最佳 k 值時是分成 5 群。


2. 請利用 Box Plot 分析，在最佳 k 值的聚類下，每個分群的特性。(5%)




透過上圖可以發現各群的個數都差不多，分別是 201、199、204、197、199。




透過上圖可以分成兩組：C2、C3 是收入較高的群，C1、C4、C5 則是收入較低的群。



透過上圖可以分成兩組：C3、C4、C5 是年齡較高的群，C1、C2 則是年齡較低。



透過上圖可以分成兩組：C2、C5 是較近期有購買的顧客，C1、C3、C4 的顧客則是在較久以前有購買行為。



透過上圖可以分成兩組：C3、C4、C5 的年花費較高，C1、C2 年花費較低


整體可以整理成下表，觀察可以發現 C5 應該是最有價值的顧客群，雖然收入低，年齡高，但是近期有來購買且年花費高。

	income	age	days since purchase	annual spend
C1	低	低	久遠	低
C2	高	低	近期	低
C3	高	高	久遠	高
C4	低	高	久遠	高
C5	低	高	近期	高

3. 請分析若你/妳是行銷部主管，在擬定行銷策略時，k=3 還是最佳 k 值較務實。(5%)

我認為在擬定行銷策略時，最佳 k 值較務實，因為根據上一題可以發現不同群集的特性都不太一樣，較好針對各群去擬定行銷策略。

流程圖四




透過 File 連至 Distances 來計算資料集中兩兩 instances 間的距離，再連至 Hierarchical Clustering 來合併分群，而透過將 Hierarchical Clustering 連至 Silhouette Plot 可以了解不同 Linkage 方法下，個資料的 silhouette value，接著利用 feature statistic widget 觀察平均值。最後為了整理在一個 data table 中進行比較，我使用 select columns/rows 抓出 silhouette，利用 create class 設定 linkage 名稱，並用 concatenate 合併，整理出最後的 data table 進行觀察。

1. 就 Top N=3，使用 Hierarchical Clustering 搭配 silhouette score 評估法，找出最佳的 linkage 方式(15%)，並將實驗結果整理在一個 Data Table 當中說明之。(10%)

Data Table (7) - Orange		
Info		
5 instances (no missing data)		
1 feature		
Target with 5 values		
1 meta attribute		
Variables		
☒ Show variable labels (if present)		
☒ Visualize numeric values		
☒ Color by instance classes		
Selection		
☒ Select full rows		
Restore Original Order		
☒ Send Automatically		
Linkage	Feature	Mean
1 Single	Silhouette (Clu...	-0.445283
2 Average	Silhouette (Clu...	-0.0907147
3 Weighted	Silhouette (Clu...	0.0964081
4 Complete	Silhouette (Clu...	-0.101446
5 Ward	Silhouette (Clu...	-0.0907147


判斷 silhouette score 時我們會挑最高的，silhouette score 代表同群內的點接近，與其他群的點較遠。因此我認為 Weighted 是最佳的 linkage 方式。

當 Linkage 為 single 時：



資料會分成資料數超級不平均的三個群集，C1 只有一個資料，C2 也只有一個資料，而剩下的資料都在 C3。另外，從 Silhouette Plot 可以看到 C1 平均值=0、C2 平均值=0、C3 平均值=-0.446


當 Linkage 為 average 時：



資料會分成資料數較 Single 平均的三個群集，然而 C1 包含了約一半以上的資料，C2 和 C3 的資料數則差不多。另外，從 Silhouette Plot 可以看到 C1 平均值=-0.524、C2 平均值=0.512、C3 平均


值=0.606

當 Linkage 為 Weighted 時：




資料會分成兩個較大的群集和一個較小的群集。另外，從 Silhouette Plot 可以看到 C1 平均值=-0.556、C2 平均值=0.498、C3 平均值=0.605

當 Linkage 為 complete 時：




資料會分成兩個較大的群集和一個較小的群集。另外，從 Silhouette Plot 可以看到 C1 平均值=-0.313、C2 平均值=0.569、C3 平均值=-0.244

當 Linkage 為 ward 時：




資料會分成一個較大的群集和兩個較小的群集。另外，從 Silhouette Plot 可以看到 C1 平均值=-0.524、C2 平均值=0.512、C3 平均值=0.606

流程圖五



1. 使用 paint data 製作出如下的四群。(5%)




新增出 C3 以及 C4，並利用 Brush 來噴出每個群集各個群集。

2. 請對上圖結果分別進行下列三種操作：

(1) 利用 dbscan 分成四群，並說明使用的參數值。(10%)

使用的參數值：

Core point neighbors = 4、Neighborhood distance = 0.173。




將繪製好的 Paint Data 連至 DBSCAN，接著，我將 Core point neighbors 設為 4，因為資料的維度是 2 維，而通常 Core point neighbors 會設為維度的兩倍。接著，調整 Neighborhood distance，一開始我將 Neighborhood distance 設為 0.149，然而將 DBSCAN 連至 Silhouette Plot 後，會發現有一些 noise。於是我調高 Neighborhood distance。最後，當 Neighborhood distance 調到 0.173 時，會沒有 noise，且會分成 4 群。


(2) 嘗試 Hierarchical Clustering 的不同 linkage 方法，說明是否能找到與上圖相似的四群。(5%)

我使用不同 linkage 方法發現只有 single 方法可以完整分類為四群。


Single:




Average:




Weighted:




Complete:



Ward:



(3) 使用 Silhouette Score 評估方式為 k-Means 選定的最佳 k 值是多少？(5%)



最佳 k 值為 8。