


流程圖一


流程圖一




圖一

1. 打開 cpu.tab，隨機取樣 30 筆資料當測試資料，其餘做為訓練資料並模仿 Bagging 的做法，訓練 5 個 Tree 模型，最後取其平均值當輸出值。


首先，我將 cpu.tab 載入，並把 class 設為 target。將匯入好的資料連接 data sampler 抽樣 30 筆當作測試資料(圖二)。接著，將 remaining data 利用 bagging 作法實現，所以使用 data sampler widget 的 bootstrap 方法(圖三)，並連接到 5 個 tree(tree 參數依照原始設定)。如此一來，剩餘的訓練資料會依序經過 bootstrap 取樣，分別產生五個不同的訓練子集，各自連接到對應的 Tree widgets (Tree - Tree(4)，所有參數沿用預設設定) 進行模型訓練。訓練完成後，這五個 Decision Tree 模型的預測結果會彙集到一個 Predictions widget 中，產生每筆測試資料對應的五組預測值。隨後，將這五組預測值利用 formula widget 進行平均(圖四)，以獲得最終的 Bagging 預測值。(圖五)



圖二



圖三




圖四

	Tree (3)	Tree (3) (error)	Tree (4)	Tree (4) (error)	Selected	MYCT	MMIN	MMAX	CACH	CHMIN	CHMAX	Average
1	14	-8	14.6667	-7.33333	No	800.0	256.0	8000.0	0.0	1.0	4.0	16.019
2	17.5	5.5	21	9	No	180.0	262.0	4000.0	0.0	1.0	3.0	20
3	68	23	82	37	No	50.0	2000.0	16000.0	12.0	3.0	16.0	85.1333
4	38	2	11	-25	No	300.0	192.0	768.0	6.0	6.0	24.0	25
5	201.5	57.5	173	29	No	75.0	2000.0	16000.0	64.0	1.0	38.0	272.967
6	11	-26	20	-17	No	900.0	2000.0	4000.0	0.0	3.0	6.0	23.35
7	26	-3	29.3333	0.333333	No	50.0	1000.0	4000.0	8.0	1.0	5.0	25.0667
8	26	-12	30.5	-7.5	No	160.0	1000.0	4000.0	8.0	1.0	14.0	30.8333
9	35	-15	38.5	-11.5	No	250.0	1000.0	16000.0	1.0	1.0	8.0	67.5
10	237	-160	405	8	No	50.0	4000.0	32000.0	112.0	52.0	104.0	384.217
11	38	16	35	13	No	140.0	2000.0	4000.0	8.0	1.0	20.0	35.4
12	40.5	-30.5	56	-15	No	50.0	2000.0	8000.0	8.0	1.0	5.0	47.5
13	29	-3	18	-14	No	105.0	1000.0	4000.0	0.0	3.0	24.0	24.5
14	14	-24	33.6667	-4.33333	No	400.0	1000.0	3000.0	0.0	1.0	2.0	29.15
15	29	2	45	18	No	50.0	2000.0	4000.0	0.0	3.0	6.0	30.34
16	35	-18	54	1	No	300.0	384.0	12000.0	6.0	1.0	24.0	60.0667
17	234.25	-34.75	224.5	-44.5	No	29.0	8000.0	32000.0	32.0	8.0	32.0	218.423
18	22.25	-22.75	26.6667	-18.3333	No	300.0	768.0	4500.0	0.0	1.0	24.0	27.7833
19	86.6667	-26.3333	98.5	-14.5	No	59.0	4000.0	12000.0	32.0	6.0	12.0	82.7333
20	14	-6	14.6667	-5.33333	No	800.0	256.0	8000.0	0.0	1.0	4.0	16.019
21	18.6667	-1.33333	29.3333	9.33333	No	50.0	500.0	2000.0	8.0	1.0	4.0	22.8
22	22	14	27.5	19.5	No	112.0	1000.0	1000.0	0.0	1.0	4.0	23.4667
23	35	-3	54	16	No	300.0	1000.0	16000.0	8.0	2.0	112.0	75.5
24	83.5	-190.5	368	94	No	25.0	1310.0	2620.0	131.0	12.0	24.0	296.667
25	114	3	74	-37	No	50.0	4000.0	16000.0	64.0	5.0	10.0	108.467
26	22.25	-29.75	18	-34	No	125.0	2000.0	8000.0	0.0	2.0	14.0	25.4833
27	237	-70	405	98	No	50.0	2000.0	32000.0	112.0	52.0	104.0	384.217
28	37.6667	5.66667	33.6667	1.66667	No	400.0	2000.0	4000.0	0.0	1.0	1.0	36.2167
29	208.8	72.8	74	-62	No	50.0	8000.0	16000.0	48.0	1.0	10.0	145.973
30	22.25	-19.75	21	-21	No	124.0	1000.0	8000.0	0.0	1.0	8.0	27.5833


圖五

2. 利用 Bagging 的結果計算 MAPE。


為了算 MAPE，所以我先計算 $\text{abs}((\text{Class-Average})/\text{Class})$ (圖六)。再使用 Select Columns 取出剛計算好的 APE 欄位(圖七)，再透過 Transpose widget 將欄轉置，方便後續彙整。最後，計算 MAPE(圖八)，再進行匯出(圖九)。最後算出來的 MAPE 是 0.376144。



圖六



圖七



圖八


	Feature 20	Feature 21	Feature 22	Feature 23	Feature 24	Feature 25	Feature 26	Feature 27	Feature 28	Feature 29	Feature 30	MAPE
1	0.199048	0.14	1.93333	0.986842	0.0827251	0.0228228	0.509936	0.25152	0.131771	0.0733333	0.343254	0.376144

圖九

3. 使用同樣的訓練、測試資料，再另外建兩個 Model，分別為 Tree 與 AdaBoost 並找出較佳的參數組合，再與剛剛前述所做的 Bagging 比較。

建立另外兩個 model，針對不同參數組合進行測試，Tree 我有調整 min number of instances in leaves，發現較佳參數是 2。Adaboost 則是調整 number of estimators，發現 estimator=15 表現

較好。觀察可以發現 Tree(5)的 MAPE 為 0.379，Adaboost 的 MAPE 為 0.325 與原本的 bagging 做比較可以發現 Adaboost 優於 bagging 優於 Tree(5)。



圖十

參數測試 Tree(5)

調整 min number of instances in leaves

設定為 5 時，MAPE=0.396

Show performance scores					
Model	MSE	RMSE	MAE	MAPE	R2
Tree (5)	17521.825	132.370	50.408	0.396	-0.855
AdaBoost	2348.400	48.460	27.467	0.350	0.751

設定為 1 時，MAPE=0.391

Show performance scores					
Model	MSE	RMSE	MAE	MAPE	R2
Tree (5)	997.859	31.589	21.778	0.391	0.894
AdaBoost	2348.400	48.460	27.467	0.350	0.751

測試 Adaboost

調整 number of estimators

設定為 20 時，MAPE=0.369

設定為 10 時，MAPE=0.457

Show performance scores					
Model	MSE	RMSE	MAE	MAPE	R2
Tree (5)	3478.569	58.979	33.704	0.457	0.632
AdaBoost	2348.400	48.460	27.467	0.350	0.751

設定為 8 時，MAPE=0.444

Show performance scores					
Model	MSE	RMSE	MAE	MAPE	R2
Tree (5)	6186.156	78.652	38.517	0.444	0.345
AdaBoost	2348.400	48.460	27.467	0.350	0.751

設定為 50 時，MAPE=0.363

設定為 10 時， $\text{MAPE}=0.350$

流程圖二


流程图一

設定為 100 時， $\text{MAPE}=0.363$

Model	MSE	RMSE	MAE	MAPE	R2
Tree (5)	630.508	25.110	18.490	0.379	0.933
AdaBoost	2260.642	47.546	26.117	0.363	0.761

流程圖二


流程图一




圖十一

4. 以 10-fold 交叉驗證方式找出三種 Model (Tree、kNN、AdaBoost)較佳的參數組合。


我針對不同參數組合進行測試，Tree 我有調整 min number of instances in leaves，發現最佳參數是 2(圖十二)。Adaboost 則是調整 number of estimators，發現 estimator=10 表現較好(圖十三)。而 kNN 則是調整 number of neighbors，發現最佳是 3(圖十四)。最終結果，三個單一模型的比較可以看下一題(圖十五)，Adaboost 優於 Tree(6)優於 kNN。



圖十二



圖十三



圖十四

參數測試 Tree(6)(只需觀察 Tree(6)的值)

調整 min number of instances in leaves

leaves=1，MAPE=0.425

Model	MSE	RMSE	MAE	MAPE	R2
AdaBoost (1)	3423.938	58.514	28.510	0.336	0.867
Tree (6)	3915.692	62.575	33.907	0.425	0.848
kNN	4099.937	64.031	33.002	0.434	0.841
Stack	2980.511	54.594	28.675	0.400	0.884

Leaves=2，MAPE=0.386(最佳)

Model	MSE	RMSE	MAE	MAPE	R2
AdaBoost (1)	3423.938	58.514	28.510	0.336	0.867
Tree (6)	2960.728	54.413	29.067	0.386	0.885
kNN	4099.937	64.031	33.002	0.434	0.841
Stack	2959.398	54.400	27.623	0.388	0.885

Leaves=5，MAPE=0.430

Model	MSE	RMSE	MAE	MAPE	R2
AdaBoost (1)	3423.938	58.514	28.510	0.336	0.867
Tree (6)	8315.631	91.190	41.020	0.430	0.677
kNN	4099.937	64.031	33.002	0.434	0.841
Stack	3288.353	57.344	28.097	0.365	0.872

Leaves=8，MAPE=0.449

Model	MSE	RMSE	MAE	MAPE	R2
AdaBoost (1)	3423.938	58.514	28.510	0.336	0.867
Tree (6)	9901.459	99.506	43.767	0.449	0.615
kNN	4099.937	64.031	33.002	0.434	0.841
Stack	3541.425	59.510	28.273	0.379	0.862

Leaves=10，MAPE=0.502

Model	MSE	RMSE	MAE	MAPE	R2
AdaBoost (1)	3423.938	58.514	28.510	0.336	0.867
Tree (6)	9195.835	95.895	44.815	0.502	0.643
kNN	4099.937	64.031	33.002	0.434	0.841
Stack	3723.121	61.017	29.062	0.382	0.855

參數測試 Adaboost (只需觀察 Adaboost 的值)

Number of estimators=10，MAPE=0.336(最佳) Number of estimators=15，MAPE=0.343

Model	MSE	RMSE	MAE	MAPE	R2
AdaBoost (1)	3423.938	58.514	28.510	0.336	0.867
Tree (6)	9195.835	95.895	44.815	0.502	0.643
kNN	4099.937	64.031	33.002	0.434	0.841
Stack	3723.121	61.017	29.062	0.382	0.855

Number of estimators=20 , MAPE=0.351

Model	MSE	RMSE	MAE	MAPE	R2
AdaBoost (1)	3346.916	57.853	28.216	0.351	0.870
Tree (6)	9195.835	95.895	44.815	0.502	0.643
kNN	4099.937	64.031	33.002	0.434	0.841
Stack	3256.119	57.062	28.746	0.371	0.874

Number of estimators=100 , MAPE=0.494

Model	MSE	RMSE	MAE	MAPE	R2
AdaBoost (1)	3377.782	58.119	30.215	0.494	0.869
Tree (6)	9195.835	95.895	44.815	0.502	0.643
kNN	4099.937	64.031	33.002	0.434	0.841
Stack	3435.188	58.610	28.481	0.398	0.867

參數測試 kNN(只需觀察 kNN 的值)

Number of neighbors=2 , MAPE=0.471

Model	MSE	RMSE	MAE	MAPE	R2
AdaBoost (1)	3423.938	58.514	28.510	0.336	0.867
Tree (6)	2960.728	54.413	29.067	0.386	0.885
kNN	3642.665	60.354	33.057	0.471	0.858
Stack	2603.201	51.022	27.839	0.409	0.899

Number of neighbors=4 , MAPE=0.449

Model	MSE	RMSE	MAE	MAPE	R2
AdaBoost (1)	3423.938	58.514	28.510	0.336	0.867
Tree (6)	2960.728	54.413	29.067	0.386	0.885
kNN	4429.789	66.557	33.656	0.449	0.828
Stack	3012.302	54.884	27.550	0.370	0.883

Number of neighbors=6 , MAPE=0.485

Model	MSE	RMSE	MAE	MAPE	R2
AdaBoost (1)	3407.136	58.371	28.448	0.343	0.868
Tree (6)	9195.835	95.895	44.815	0.502	0.643
kNN	4099.937	64.031	33.002	0.434	0.841
Stack	3059.454	55.312	28.517	0.365	0.881

Number of estimators=50 , MAPE=0.432

Model	MSE	RMSE	MAE	MAPE	R2
AdaBoost (1)	3418.408	58.467	29.880	0.432	0.867
Tree (6)	9195.835	95.895	44.815	0.502	0.643
kNN	4099.937	64.031	33.002	0.434	0.841
Stack	3465.870	58.872	28.338	0.386	0.865

Number of neighbors=3 , MAPE=0.434(最佳)


Model	MSE	RMSE	MAE	MAPE	R2
AdaBoost (1)	3423.938	58.514	28.510	0.336	0.867
Tree (6)	2960.728	54.413	29.067	0.386	0.885
kNN	4099.937	64.031	33.002	0.434	0.841
Stack	2959.398	54.400	27.623	0.388	0.885

Number of neighbors=5 , MAPE=0.472

Model	MSE	RMSE	MAE	MAPE	R2
AdaBoost (1)	3423.938	58.514	28.510	0.336	0.867
Tree (6)	2960.728	54.413	29.067	0.386	0.885
kNN	5259.798	72.524	35.144	0.472	0.796
Stack	3113.818	55.802	27.377	0.367	0.879

Model	MSE	RMSE	MAE	MAPE	R2
AdaBoost (1)	3423.938	58.514	28.510	0.336	0.867
Tree (6)	2960.728	54.413	29.067	0.386	0.885
kNN	5792.219	76.107	36.238	0.485	0.775
Stack	3133.520	55.978	27.726	0.362	0.878

5. 將上述的三種 Model 當成 Stacking 的 level-0 模型，組合後模型是否會優於單一模型？
- 將三種 model 作為 stacking 的 level-0 模型可以發現，Adaboost 的 MAPE 最低，表現最好。接著依序是 Tree(6)、stack、kNN(圖十五)。



圖十五