



流程圖一




1. 使用 select rows 從屬性 x, y, z 中找出不合理的 8 筆資料。
- 依據常理判斷，x, y, z 都不應該小於等於 0，因此利用 select rows widget 排除不合理的資料。




2. 捨去前述的 8 筆資料，並將 price 設為 target 後，儲存為 diamonds_R1.csv。(5%)

利用 select column widget 將 price 移動到 target，並利用 save data widget 將篩選過後的檔案存成 diamonds_R1.csv。



流程圖二





1. 打開 diamonds_R1.csv，用四分圖法找出 outliers（只考慮數值型態的屬性，包含 price），接著說明 outliers 數量是否為 6402 筆？

利用 box plot widget 去計算 $1.5 \times \text{IQR}$ ，進而計算 Outlier 所在區間。

先求 $1.5 \times \text{IQR}$


Price	$1.5 \times \text{IQR} = 1.5 \times (5324 - 949.5) = 6561.75$	Outlier > 11885.75 or Outlier < -5612.25
Carat	$1.5 \times (1.04 - 0.4) = 0.96$	Outlier > 2 or Outlier < -0.56
Depth	$1.5 \times (62.5 - 61) = 2.25$	Outlier > 64.75 or Outlier < 58.75
Table	$1.5 \times (59 - 56) = 4.5$	Outlier > 63.5 or Outlier < 51.5
x	$1.5 \times (6.54 - 4.71) = 2.745$	Outlier > 9.285 or Outlier < 1.965
y	$1.5 \times (6.54 - 4.72) = 2.73$	Outlier > 9.27 or Outlier < 1.99
z	$1.5 \times (4.04 - 2.91) = 1.695$	Outlier > 5.735 or Outlier < 1.215


計算出 IQR 後利用 Select rows widget 把 outlier 篩選掉，並將 unmatched data 存在 data table，觀察 data table 左上可以發現有 6402 筆資料。




2. 捨去 outliers 後，將資料存為 diamonds_R2.csv（確定有 47530 筆資料）

將 matching data 存入 data table 中，觀察 data table 可以發現左上顯示有 47530 筆資料，並將這些資料用 save data widget 存成 diamonds_R2.csv。





流程圖三





1. 打開 diamonds_R1.csv，利用 test and score（Cross Validation, Number of fold: 5,Stratified）比較預設 Random Forest（Number of trees: 100）與預設 AdaBoost 的 RMSE 與 Training Time。

使用 Random Forest（Number of trees: 100）與預設 Adaboost 觀察可以發現

Random Forest: Training time = 30.613, RMSE=547.979


Adaboost: Training time = 187.700, RMSE=604.462






2. 承上題，若 Random Forest 當中 Number of tree: 100 必須維持不變，請另找出一組參數可以使得 RMSE 和 Training Time 超越預設 Random Forest。

我將 Limit depth of individual trees 設定成 50，Do not split smaller than 設定成 6，如此可以發現 training time 是 227.392，比原先的 187.700 大。




3. 使用 Random Forest 搭配 Rank，依序排列出屬性的重要性。

這裡使用 Rank widget，觀察後可以發現重要性從最高到最低依序是 carat, y, clarity, color, z, x, depth, table, cut。




流程圖四




1. 使用預設的 Random Forest，比較 diamonds_R1.csv 與 diamonds_R2.csv 的效能。


觀察 test and score widget 可以發現 diamonds_R2.csv 檔案在所有指標事都表現得比 diamonds_R1.csv 好。



流程圖五



1. 打開 diamonds_R1.csv 以各項指標比較預設的 Random Forest 與四種預設的 Gradient Boosting。



觀察 test and score 可以發現，xgboost 表現為四個預設 gradient boosting 中最好，catboost 第二好。然而缺點是訓練時間較長，接著是 scikit-learn，而 xgboost random forest 在所有的指標都表現非常差，並且差異和其他幾個方法有巨大差距。預設 random forest 則是在這組數據上誤差最低（MAPE 最低），且 R²也非常接近 xgboost 和 catboost，我認為是最穩定的選擇。